Rapport de validation — tests et donnees

Ce que verifie le pipeline avant de toucher a vos images

Ce notebook couvre deux questions independantes :

1. **Le validateur fonctionne-t-il ?** — Tests unitaires sur des images synthetiques, l'equivalent de `make test`.
2. **Mes donnees sont-elles pretes ?** — Validation de vraies images depuis `data/test_images/`, l'equivalent de `make validate`.

Partie 1 — Tests unitaires

Ce que teste `make test`

`make test` lance `pytest tests/` sur deux fonctions de `scripts/validate_input.py` : `check_csv()` et `check_image()`. Chaque test fabrique une situation problematique precise et verifie que le validateur la detecte.

Resultat pytest

```
============================= test session starts ==============================
platform linux -- Python 3.11.15, pytest-9.0.3, pluggy-1.6.0 -- /root/miniconda3/envs/gmic/bi
cachedir: .pytest_cache
rootdir: /root/projet_cancer_sein
configfile: pyproject.toml
collecting ... collected 14 items

tests/test_validate_input.py::TestCSV::test_valid_csv PASSED             [  7%]
tests/test_validate_input.py::TestCSV::test_missing_csv PASSED           [ 14%]
tests/test_validate_input.py::TestCSV::test_csv_is_a_directory PASSED    [ 21%]
```

```
tests/test_validate_input.py::TestCSV::test_missing_columns PASSED       [ 28%]
tests/test_validate_input.py::TestCSV::test_invalid_laterality PASSED    [ 35%]
tests/test_validate_input.py::TestCSV::test_invalid_view PASSED          [ 42%]
tests/test_validate_input.py::TestImages::test_valid_grayscale PASSED    [ 50%]
tests/test_validate_input.py::TestImages::test_rgb_image_rejected PASSED [ 57%]
tests/test_validate_input.py::TestImages::test_tiny_image_warns PASSED   [ 64%]
tests/test_validate_input.py::TestImages::test_black_image_rejected PASSED [ 71%]
tests/test_validate_input.py::TestImages::test_corrupted_file PASSED     [ 78%]
tests/test_validate_input.py::TestImages::test_white_image_rejected PASSED [ 85%]
tests/test_validate_input.py::TestImages::test_large_image_warns PASSED  [ 92%]
tests/test_validate_input.py::TestImages::test_uint8_valid PASSED        [100%]

============================== 14 passed in 1.54s ==============================
```

Tests CSV — ce qui est verifie

`check_csv()` lit votre `train.csv` et controle quatre points :

```python
# validate_input.py · lignes 99-125
missing = EXPECTED_CSV_COLS - columns        # colonnes obligatoires presentes ?
bad_lat = set(df["laterality"]) - {"L","R"}  # lateralite = L ou R uniquement
bad_view = set(df["view"]) - {"CC","MLO"}    # vue = CC ou MLO uniquement
cancer_vals.issubset({0, 1})                 # label cancer = 0 ou 1 uniquement
```

Test	Situation simulee	Resultat attendu
`test_valid_csv`	CSV correct, 8 lignes, toutes colonnes	`passed=True`
`test_missing_csv`	Chemin inexistant	Erreur « introuvable »
`test_csv_is_a_directory`	Un *dossier* nomme `train.csv`	Erreur « dossier »
`test_missing_columns`	Seulement `patient_id` et `image_id`	Erreur « Colonnes manquantes »
`test_invalid_laterality`	Valeur `Left` au lieu de `L`	Erreur « Lateralites invalides »
`test_invalid_view`	Valeur `XRAY` au lieu de `CC`/`MLO`	Erreur « Vues invalides »

Tests images — ce qui est verifie

`check_image()` applique trois criteres sur chaque image :

```
# validate_input.py · lignes 168-208
if img.shape[2] == 3:           # couleur RGB → rejet immediat
if h < 700 or w < 700:         # trop petite → warning (pipeline continue)
if max(h, w) > 5000:           # tres grande → warning
if (pmax - pmin) < 50:         # uniforme (noire/blanche) → rejet (image corrompue)
```

Les seuils (`MIN_IMAGE_SIZE=700`, `MIN_PIXEL_RANGE=50`, `VERY_LARGE_DIM=5000`) sont definis aux lignes 25–27 de `validate_input.py` — modifiables si besoin.

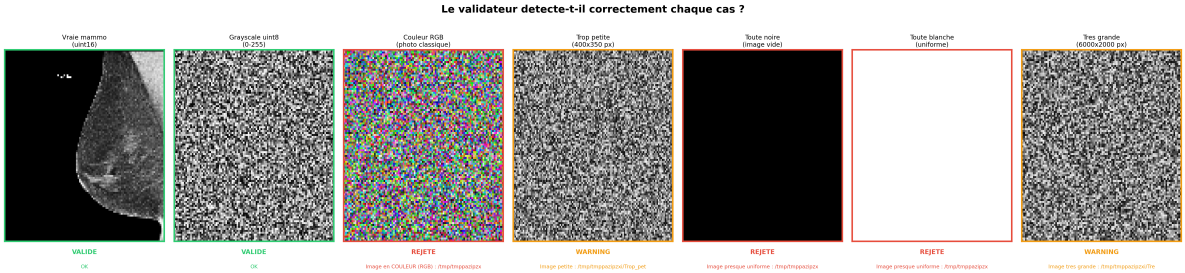

Test	Situation simulee	Resultat attendu
`test_valid_grayscale`	Vraie mammographie uint16	Valide
`test_uint8_valid`	PNG 3000x2000 uint8	Valide
`test_rgb_image_rejected`	Image couleur RGB	Erreur « COULEUR »
`test_tiny_image_warns`	PNG 400x350 px	Warning « petite »
`test_black_image_rejected`	PNG entierement noir	Erreur « uniforme »
`test_white_image_rejected`	PNG entierement blanc	Erreur « uniforme »
`test_large_image_warns`	PNG 6000x2000	Warning « grande »
`test_corrupted_file`	Fichier `.png` contenant du texte	Erreur « illisible »

Partie 2 — Validation de vraies images

Ce que fait `make validate`

`make validate INPUT_DIR=...` appelle `check_csv()` puis `check_images()` sur vos vraies donnees. Les images ci-dessous viennent de `data/test_images/` — elles simulent ce qu'un utilisateur pourrait soumettre par erreur (photos, screenshots, fichiers web).

```python
# validate_input.py · lignes 230-254
SUPPORTED_FORMATS   = (".png", ".dcm", ".dcm.zip")
UNSUPPORTED_FORMATS = (".jpg", ".jpeg", ".webp", ".avif", ...)
# Les formats non supportes sont rejetes avant meme d'ouvrir l'image.
```

```
DIAGNOSTIC - data/test_images/
====================================================
  Blanc.png                                        [FAIL]  Image RGBA (avec transparence) : /ro
  color_splash.png                                 [FAIL]  Image en COULEUR (RGB) : /root/proje
  images.jpg                                       [FAIL]  Format non supporte (.jpg)
  photo-stone-texture-pattern_58702-16052.avif     [FAIL]  Format non supporte (.avif)
  shooting-anniversaire-bebe-un-an-garcon-decor    [FAIL]  Format non supporte (.webp)
  wilderness_picture_cute_small_squirrel_branch    [FAIL]  Format non supporte (.jpg)
```